

TP 7

Dask Dataframe & Distributed Learning

Master SID 1 SD
Benoist GASTON
benoist.gaston@univ-rouen.fr

Dask

Exercice 01 Persistance des données

- Le notebook `M1SD-HPC-TP07-Ex01-Persistance.ipynb` présente un traitement pandas. Le répertoire `data/` contient une série de fichiers Parquet. Chaque fichier contient des informations sur des maisons avec les colonnes suivantes : `surface`, `chambres`, `distance_centre`, `anciennete`, et `prix`.
- Le traitement effectué consiste à charger un fichier Parquet et à retourner la moyenne, l'écart type et le maximum du prix.

- **Questions**

1. Parallélisation avec Dask

1. Réaliser un traitement équivalent avec des `dask dataframe`
2. Comparer les temps de restitution des versions pandas et Dask pour des volumétries de données croissantes.

2. Optimisations

1. Utiliser la méthode `persist()` pour éviter les chargements redondants de données.
2. Comparer les temps de restitution entre la version Dask optimisée avec `persist()` et les versions précédentes.

Dask

Exercice 02 Persistance des données

- Le notebook `M1SD-HPC-TP07-Ex02-DistributedTraining.ipynb` présente l'entraînement d'un modèle à partir de fichier chargé avec pandas.
- On utilise les mêmes données que pour l'exercice précédent.
- Le traitement effectué consiste à charger un fichier Parquet de training et entraîner un modèle `SGDRegressor` sur ce jeu de données avec pour cible le prix.
- **Questions**
 1. Observer les temps de restitution pour des volumétries de données croissantes.
 2. Utiliser Dask dataframe pour distribuer le jeu de données et adapter l'entraînement sur le jeu de données distribuer :
 1. Mapper le `partial_fit` sur le dask dataframe
 2. Réduire les poids, pour simplifier le développement on se propose de réduire suivant la moyenne
 3. Comparer les temps de restitution avec la version initiale
 4. Proposer des optimisations